

## TD 2 : problème d'optimisation et convexité

**Exercice 1.** Soient  $p^1 = (p_1^1, p_2^1)$ ,  $p^2 = (p_1^2, p_2^2)$ ,  $\dots$ ,  $p^n = (p_1^n, p_2^n)$   $n$  points dans  $\mathbb{R}^2$ . Le but de cet exercice est de trouver le point qui minimise la somme des distances au carré à tous les points  $p^i$  : ainsi, pour tout  $x = (x_1, x_2)$  nous définissons la fonctionnelle suivante :

$$J(x) = \sum_{i=1}^n \|x - p^i\|^2.$$

1. Calculer  $\frac{\partial J}{\partial x_1}(x)$  et  $\frac{\partial J}{\partial x_2}(x)$ , et en déduire que  $J$  admet un unique point critique  $x^*$  sur  $\mathbb{R}^2$  à déterminer. Comment s'appelle ce point en termes géométriques ?
2. Montrer que  $x^*$  est un minimiseur local de  $J$ .
3. Expliquer pourquoi  $x^*$  est aussi l'unique minimiseur global de  $J$ .

**Exercice 2. Régression linéaire simple** Soit  $(x_i, y_i)_{i=1}^n$  un  $n$ -uplet de points dans  $\mathbb{R}^2$ , avec  $n \geq 2$ . On suppose qu'au moins deux points  $x_i$  sont distincts. La régression linéaire simple consiste à trouver une relation affine  $y = \alpha x + \beta$  qui s'adapte au mieux aux observations, ce qui s'obtient en minimisant la fonctionnelle suivante dans  $\mathbb{R}^2$  :  $J(\alpha, \beta) = \sum_{i=1}^n (\alpha x_i + \beta - y_i)^2$

1. Montrer que cette fonctionnelle admet un minimiseur global unique et le calculer.
2. Écrire une fonction `RegressionLineaire(x,y)` qui calcule cette solution à partir de vecteurs `x`, `y` donnant les coordonnées des points. La fonction doit renvoyer deux variables `alpha` et `beta` correspondant aux coefficients calculés. Tester cette fonction pour

```
x = np.random.rand(100)
y = -5 + 12*x + np.random.randn(100)
```

et afficher sur le même graphique les points et la droite de régression.

**Exercice 3. Modèle linéaire** Soient  $(x_i, y_i)_{i=1}^n$  un  $n$ -uplet de points de  $\mathbb{R}^2$ . Nous cherchons à trouver une relation entre les variables  $x_i$  et  $y_i$ . On considère le modèle

$$f(x) = \sum_{j=0}^k \beta_j w_j(x),$$

où les  $w_j$  sont des fonctions de  $\mathbb{R}$  dans  $\mathbb{R}$  et les  $\beta_j$  sont des coefficients. On cherche les coefficients  $\beta_j$  qui s'adaptent le mieux au modèle  $y_i = f(x_i)$  pour  $i = 1, \dots, n$  en minimisant

$$J(\beta_0, \dots, \beta_k) = \sum_{i=1}^n \left( \sum_{j=0}^k \beta_j w_j(x_i) - y_i \right)^2.$$

On supposera que  $n \geq k + 1$ .

1. Montrer que l'on peut écrire

$$J(\beta) = \|M\beta - y\|^2,$$

où  $\beta = (\beta_0, \dots, \beta_k)^T$ ,  $y = (y_1, \dots, y_n)^T$ , et  $M$  est une matrice à définir.

2. Montrer que le vecteur  $\beta$  des coefficients optimaux satisfait  $M^T M \beta = M^T y$ .
3. Montrer que si  $M$  est de rang maximal alors la solution est unique.
4. On considère le cas de la régression polynomiale :  $w_j(x) = x^j$ . Écrire une fonction **Regression-Polynomiale(x,y,k)** qui calcule cette solution à partir de vecteurs **x**, **y** donnant les coordonnées des points, et de l'ordre  $k$ . La fonction doit renvoyer un vecteur **beta** dans  $\mathbb{R}^{k+1}$  correspondant aux coefficients calculés. Tester cette fonction pour

```
x = np.random.rand(100)
y = -5 + 12*x - 3*x**2 + np.random.randn(100)
k = 3
```

et afficher sur le même graphique les points et la courbe de régression.